

第九届全国大学生生物医学工程创新设计竞赛
预赛作品报告

基于逐帧体积计算的
心脏射血功能
评估方案



作品 ID 号: 7245

参赛学生类型: 本科生

参加赛道: 心脑血管类诊疗(影像类)

组别: 自选项目组

2024 年 7 月

内容完整性自查表

说明：

1. 命题组参赛作品请根据命题文件规定或要求的指标填写；
2. 自选组参赛作品请根据实际参赛作品完成情况填写。

完整性类别	任务或技术指标名称	完成效果	呈现方式 (报告中的章节、页码, 或者测试报告, 或实物、视频等)
参赛作品任务或技术指标要求	1.四腔室分割 Dice 系数	0.982174190	7
	2.二腔室分割 Dice 系数	0.986308459	8
	3.四腔室 Hausdorff 距离	21.064782	7
	4.二腔室 Hausdorff 距离	22.22173114	8
	5. 四腔室 L-A 模拟法射血分数 MAE	4.273083555	12
	6. 四腔室单平 Simpson 法射血分数 MAE	7.722260683	11
	7.改良 Simpson 法射血分数 MAE	3.144390152	13
其他	8.四腔室 L-A 模拟法射血分数与标准值 R^2	0.852773902	12
	9.四腔室单平面 Simpson 法射血分数与标准值 R^2	0.89753794	11
	10.改良 Simpson 法射血分数与标准值 R^2	0.942115522	14
	11.时空卷积评价	MAE = 4.0% RMSE = 5.3% $R^2 = 0.81$	16
	12.上采样算法评价	SSIM = 0.974475017 MSE = 11.44406738 RMSE = 0.013136743 PSNR = 37.743132	15

摘 要

心脏疾病是全球主要的健康负担之一，准确的心脏功能评估对于心脏疾病的诊断、治疗和预后判断至关重要。射血分数 (EF) 作为心脏泵血功能的关键指标，其精准测量对临床决策极为关键。

本研究依托超声心动图和人工智能技术，开发了一种基于超声心动图的心脏结构自动分割和射血分数计算方法。研究设计了一个包含结构分割臂和时空分析臂的综合方案，使用 U-Net+++ 模型实现了左心室、左心房与心室壁的精准自动分割，并采用了三种方法：四腔室 L-A 模拟法，四腔室单平面 Simpson 法和改良 Simpson 法计算射血分数，其中，改良 Simpson 法同时兼顾了四腔室与二腔室影像的分析，实现了对心脏结构的容积识别。

研究结果显示，四腔室分割 Dice 系数为 0.982，二腔室分割 Dice 系数为 0.986，充分验证了分割算法的精确性。改良 Simpson 法在射血分数计算中表现最佳，射血分数计算值与真实值之间的平均绝对系数 MAE 为 3.14，判定系数 R^2 为 0.942。此外，本研究所探讨的上采样算法和心动周期分割与射血分数平均化的方法，能够处理低质量影像并增强预测的准确性；同时融合射血分数与患者人类学数据预测心力衰竭，拓宽了应用范畴。

本研究所开发的心脏结构自动分割和射血分数计算方法不仅具有科学性与高效性，而且在提升心脏疾病诊断精度与效率方面具有巨大潜力，为临床决策提供了有力的技术支持。

关键词：射血分数，超声心动图，深度学习，U-Net+++，改良 Simpson 法

目 录

摘要.....	I
1 作品概述.....	1
1.1 背景及意义	1
1.2 国内外研究现状	1
1.3 研究基础和目标	2
2 作品方案设计及实现.....	3
2.1 作品技术路线.....	3
2.1.1 结构分割臂	3
2.1.2 时空分析臂	4
2.1.3 射血分数计算和心力衰竭预测	4
2.2 技术方案对比.....	5
2.2.1 图像分割方案	5
2.2.2 射血分数计算方案	5
3 作品实现与结果展示.....	7
3.1 深度学习模型训练与性能评价	7
3.1.1 四腔室识别分割模型	7
3.1.2 二腔室识别分割模型	8
3.2 射血分数的计算	9
3.2.1 基于四腔室影像补全的射血分数计算与评价.....	11
3.2.2 基于四腔室和二腔室影像的射血分数计算与评价	12
3.3 逐帧处理和帧连接分析.....	14
3.3.1 上采样性能评价	14
3.3.2 心动周期分割与射血分数平均化.....	15
3.4 心力衰竭预测与综合评价.....	16
4 总结与展望	18
4.1 总结	18
4.2 在生成式人工智能与综合大模型时代的展望	18
参考文献.....	20

1 作品概述

1.1 背景及意义

心脏疾病是全球主要的健康负担之一，准确的心脏功能评估对于心脏疾病的诊断、治疗和预后判断至关重要。射血分数 (EF) 作为心脏泵血功能的关键指标，其测量结果直接影响到临床决策和患者管理。传统的 EF 测量方法主要依赖于超声心动图，需要专业人员手动追踪心脏边界，计算左心室舒张末期容积 (EDV) 和收缩末期容积 (ESV)，该过程不仅耗时冗长，而且深受主观判断与经验积累的影响，因此，所获取的测量结果往往呈现出较高的变异性，难以保证结果的稳定性和一致性。在追求精确医疗诊断的今天，减少这类不确定因素，提高测量的客观性和可靠性，显得尤为重要。

随着医学影像技术和人工智能算法的快速发展，自动化和智能化的心脏功能评估方法成为可能。不仅可以减少人力成本，提高效率，同时可以减少人为误差，提高测量的准确性和重复性。此外，自动化方法能够提供连续的心脏周期分析，有助于检测细微的心功能变化，对于早期诊断和及时治疗心脏疾病具有重要意义。

本项目针对现有技术的局限性，提出了一种基于超声心动图的射血分数自动化计算方法。该方法通过时空卷积与结构分割的深度学习组合方法，实现左心室、左心房与心室壁的自动分割，自动识别其舒张末期容积 (EDV) 和收缩末期容积 (ESV)，从而准确计算射血分数。本研究不仅有望提高射血分数测量的准确性和效率，而且通过增强计算过程的可解释性，有助于医生更好地理解心脏功能状态，为心脏疾病的诊断和治疗提供更加可靠的依据。

1.2 国内外研究现状

左心室射血分数 (LVEF) 是评估心脏功能的重要指标，对于诊断和治疗心脏病具有重要意义。LVEF 的计算通常依赖于医学影像技术，如超声心动图、心脏磁共振成像 (CMR) 等。随着技术的发展，自动化和智能化的计算方法逐渐成为研究热点。在国内外研究现状方面，已有多种方法用于左心室的分割和 LVEF 的计算。传统的左心室分割技术依赖于手动分割或半自动工具，这些方法耗时且易受操作者主观性影响。

近年来，深度学习技术在医学图像分析领域取得了显著进展。在 MRI 领域，研究者们探索了使用深度学习进行图像分割分割。2019 年 Liu 等^[1]开发了一个包含 inception 模块的密集型 U-Net，结合多尺度特征对具有较大结构变异性的图像进行稳健分割。此外毕宇琪等提出了一种基于 SwinU-Net 的心脏医学图像分割算

法^[2]，该算法结合了 Swin Transformer 和 U-Net 结构，以实现更强大的特征提取和分割性能。而在超声心动图领域，也有更多的研究者探索基于深度学习的自动分割和功能评估。例如，通过一种基于深度学习的方法，具体来讲是指通过简化的 U-Net 神经网络直接从超声心动图图像中估计 LVEF^[3]。这种方法通过减少卷积层中的过滤器数量并移除最深层，降低了模型复杂度，同时保持了与原始网络相当的性能。实验结果显示，该方法在自动估计 LVEF 方面具有较低的均方误差（MAE）和较高的决定系数 R^2 值。Meghan Muldoon 等^[4]提出了一个基于 Mobile U-Net 的轻量级网络，用于在心脏超声视频中分割左心室，并基于 Simpson 的单平面方法实现了一个无监督的 LVEF 估算算法。在大型公共数据集上的实验结果表明，所提出的方法在保持与现有技术相当的准确性的同时，显著提高了空间和时间效率。Márton Tokodi 等人^[5]使用多个时空卷积神经网络来预测从 2D 心脏超声视频中得出的右心室射血分数（RVEF），集成模型在内部验证集的平均绝对误差为 4.57%，在外部验证集为 5.54%，与专家的视觉评估相当。此外还有研究^[6]介绍了一种基于 2D 超声心动图的深度学习方法，用于自动化左心室射血分数的评估。该研究开发了一种基于 U-Net 的 DL 算法（DPS-Net），并应用双平面辛普森方法进行 LVEF 计算。研究结果表明，DPS-Net 在不同心脏疾病表型和超声系统中表现出色，具有高诊断性能。

尽管深度学习方法在左心室分割和 EF 计算方面取得了显著进展，但仍存在一些问题和局限性。首先，深度学习方法通常需要大量的训练数据，对于小样本、低分辨率或低质量的心脏图像，其分割效果可能受限。其次，计算复杂度高，对于实时性要求较高的临床应用可能存在挑战。此外，现有方法对于心脏图像中的噪声、伪影以及个体差异的处理仍需进一步优化。

1.3 研究基础和目标

本研究项目旨在提出一种基于超声心动图的射血分数自动化计算方案，通过构建卷积神经网络（CNN）模型，整合时空卷积和结构分割的深度学习技术，实现自动识别和分割左心室、左心房以及心室壁，进而准确计算左心室射血分数（LVEF）。

为了应对实际应用中的复杂情况和权威数据集中的数据质量问题，本项目有必要开发专用的上下采样方法，并对数据缺失和影像缺陷进行优化。通过这些方法，我们旨在提升 LVEF 测量的精确度和效率，并增强计算过程的透明度，以便更准确地解读心脏功能状态，为心脏疾病的诊疗提供可靠的依据。此外，我们将考察截至 2024 年 6 月的新型分割理念与实际模型，研究如何利用生成式 AI 增强训练数据集的多样性和模型的泛化能力。

2 作品方案设计及实现

2.1 作品技术路线

为了实现基于超声心动图的结构自动分割和射血分数计算，我们开发了一个基于逐帧分析和帧与帧连接的综合方案。该方案涵盖了“结构分割臂”和“时空分析臂”，分别对应逐帧的结构分割和帧与帧间连接的分析。此两臂相互结合，能够完成对未经标注的心动超声视频的处理识别。在此基础上，我们搭建了用于计算射血分数的诸多计算方法，并且通过射血分数和其他患者信息（若存在）共同实现心力衰竭的预测。

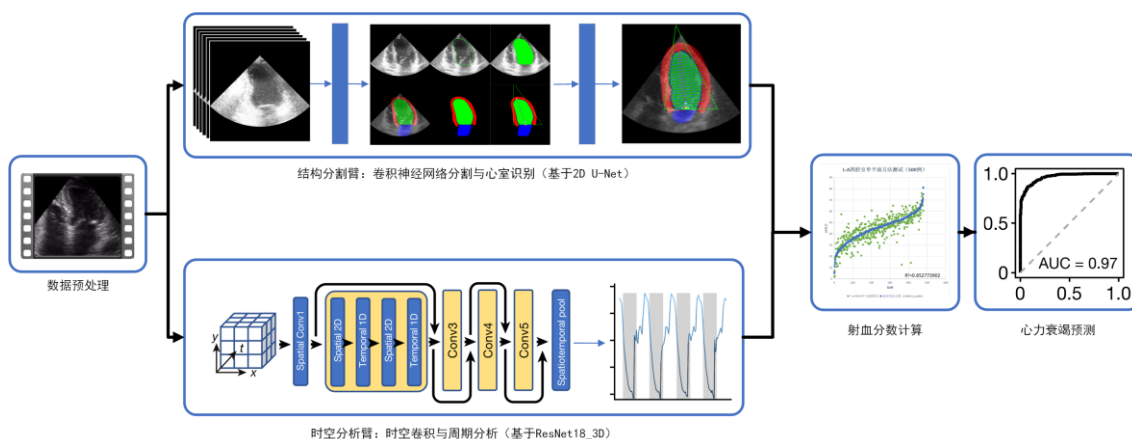


图 2.1 作品技术原理

2.1.1 结构分割臂

“结构分割臂”使用基于卷积神经网络（Convolutional Neural Network, CNN）的相关模型进行训练，搭配基本图像图形处理算法，能够实现对心脏图像中各个区域的精确识别和分割，包括左心房、左心室、二尖瓣等关键结构。在本方案中，我们使用了经过训练集加强优化的 U-Net+++模型完成这部分的工作。

我们使用 CAMUS_public 数据集提供的 500 例患者的半心动周期的超声影像及其标注制作了二腔室、四腔室各自的左心房、左心室、心室壁结构标签。经过视频切片、边缘补全（统一为 512×512 像素黑色背景）、下采样等处理，统一保存为 8 位灰度，96dpi 的 256×256 像素 PNG 格式图片。其中前 400 例作为训练集，401~500 例作为测试集。四腔室和二腔室别涉及 9964 和 9268 张图片。所有图片和标签均经过人工视觉检查。随后，在 1 块 NVIDIA GeForce RTX 4090 上完成训练，共得到 6 个高精度的 path 文件，每个文件平均需要 6 小时。

分割完成后,经过我们开发的基于 O'Rourke 原理^[4]算法,实现对左心室结构外接最小三角形的自动勾画,同时通过确定方向的外接最小三角形获取二尖瓣环中点和心尖位置,即可计算长轴。左心室像素点数量和长轴可以间接或直接用于心室体积以及射血分数的计算。

2.1.2 时空分析臂

“时空分析臂”则是在结构分割的基础上,对心脏的动态变化进行深入的分析。通过对心脏图像序列进行时空卷积,能够捕捉到心脏在收缩和舒张过程中的运动和变形情况,从而得到心脏的时空特征。经过比较,我们训练了一个 ResNet18_3D 模型,它具有跨帧的残差连接和,在网络卷积中集成了空间和时间信息,从而实现对心室运动趋势的追踪。

时空分析臂主要是为了处理现实中的心动超声视频,通过对 ED 和 ES 帧的标记,学习出含有多个心动周期的视频里的心室“涨落”规律,从而完成对视频的分段以及各周期 ED 和 ES 帧的获取,加入到射血分数的计算中。该部分的训练与检测主要基于 EchoNet-Dynamic 数据集^[7]进行训练与测试。

为了应对数据集和一部分现实视频的低图像质量,我们开发了多次插值预测的上采样方法,将清晰度低于 128×128 像素的图片填充边缘后上采样至 256×256 。该上采样算法的实际性能会在后文中呈现。上采样后的图像有效提高该方案对低质量影像的宽容。

2.1.3 射血分数计算和心力衰竭预测

射血分数计算和心力衰竭预测是本方案的核心部分。在考虑到现实情况和数据质量后,我们同时开发了仅基于四腔式影像的 EF 计算方法和四腔二腔联合方法,共三种计算方法。这三种方法的形式与评价效能将在后文逐一呈现。对于两者兼有的影像,我们主要采用改良 Simpson 法(双尖圆盘积分法)。而对于仅有四腔室的情形,除了传统的单平面 Simpson 法,我们还提出了一种“L-A 模拟体积法”,仅利用面积和长轴实现预测。

在获取患者的射血分数后,我们结合患者的其他人类学信息进行对可能存在的心力衰竭的预测^[8]。

2.2 技术方案对比

2.2.1 图像分割方案

随着人工智能和深度学习技术的快速发展，图像分割方法日新月异，基于生成式 AI 推理的 SAM 和类 SAM（例如 MedSAM 与 MedSAM_lite）^[9]模型崭露头角。

考虑到本方案的任务重点更倾向于精准的边缘分割而不是语义分割，对于实际存在的劣质视频数据，更准确地区分、计量像素有着更高的优先级。我们尝试使用预训练的 MedSAM_lite 模型对 128×128 大小的灰度图像进行分割，其结果不能证实比传统的卷积神经网络模型有优势。

常见的 CNN 模型包括 FCN、VNet、ResNet、DeepLab 及其变体等等，以及一些引入了更多交互机制的实例分割模型。与这些模型相比，U-Net 具有诸多优点。U-Net 通过跳跃连接将编码器的特征图与解码器的特征图相结合，使得模型在分割时能够同时利用局部和全局的上下文信息。由于在解码器中使用上采样和跳跃连接，因此 U-Net 能更精确地定位对象边界。U-Net 能够通过少量的训练样本来学习有效的特征，而且 U-Net 是一个端到端的网络，可以直接从原始图像输入到分割输出，这使得训练和推理过程更加简单和高效。

基于此，我们决定尝试在 U-Net 的基础上进行修改，精准实现结构分割的任务。Huimin Huang^[10]等在 2020 年提出了 U-Net+++（以下简称 U-Net3+）模型，该模型与 U-Net 和 U-Net++相比，通过重新设计跳跃连接、利用多尺度的深度监督将多尺度特征结合起来，只需要比它们更少的参数，却可以产生更准确的位置感知和边界增强的分割图。

无论是 U-Net 中的直接连接还是 U-Net++中的密集嵌套连接，都缺乏从全尺度探索足够信息的能力，因此不能明确地得知器官的位置和边界。U-Net 3+中的每个解码器层都融合了来自编码器的较小和相同尺度的特征图以及来自解码器的较大尺度的特征图，能够捕获了全尺度下的细粒度语义和粗粒度语义。对于该任务更有裨益。

2.2.2 射血分数计算方案

射血分数（Ejection Fraction, EF）是衡量心脏收缩功能的重要指标，计算公式如式 2.1 所示。

$$EF = \frac{EDV - ESV}{EDV} \times 100\% \quad (2.1)$$

其中 EF 代表射血分数，EDV 和 ESV 分别代表左心室在舒张末期和收缩末期的容积量。不同的计算方法适用于不同的临床情况。

Simpson 方法基于一定的几何假设，将心室近似于半椭球或者“子弹头”形状。在计算心室容积时，利用微元思想，将心室切分成多个等分切面，计算每个切面的容积，其总和即为心室的容积。如图 2.2 所示， a_i 和 b_i 分别为四腔室视野（A4C）和二腔室视野（A2C）切面 LV 的水平横径， L 为左室长轴的长度。




图 2.2: Simpson 方法计算 LV 容积原理图

$$V_i = \left(\pi \frac{a_i \cdot b_i}{4} \right) \times \frac{L}{n} \quad (2.2)$$

计算心室每个等分切面的容积相当于计算单个椭圆体的容积。将心室进行 n 等分，由公式 2.3 计算单个椭圆体的容积，再由公式 2.3，计算 n 等分椭圆体的容积之和，即心室容积。接着，利用公式 2.2 计算 EF。

$$V = \frac{\pi}{4} \sum_{i=1}^n (a_i \cdot b_i) \times \frac{L}{n} \quad (2.3)$$

除此以外，当只有四腔室影像时，则使用单平面的 Simpson 方法，区别为将 b_i 直接用 a_i 表示。为了更广泛应用于实际任务，我们同时开发了单平面和双平面方法。当无法使用双平面方法时，自动调用单平面方法生成数据。

3 作品实现与结果展示

3.1 深度学习模型训练与性能评价

3.1.1 四腔室识别分割模型

本研究分别训练了四腔室和二腔室的 U-Net3+ 识别模型，分别实现两种视图下腔室结构的分割。其中，着重训练了两个视野下的左心室识别。

使用 256×256 的 PNG 图片进行训练。训练模型 U-Net3+，迭代轮数 EPOCHS = 100，批数量 BATCH_SIZE = 20，每个 Epoch 包含 499 个 Batch（共 9964 张图片和 9964 个标签）。更改标签类型（左心房 LA，左心室 LV，心室壁 VM）分别训练。

前期模型学习率 LR=0.1，在模型接近 BEST LOSS 后调整 LR=0.001。

缩放因子 SCALE = 5，像素区分阈值 THRESHOLD = 0.5。

训练完成形成 path 文件并输出 BEST LOSS（最佳损失函数）。

训练结果：

LV BEST LOSS= 0.13264347835330065

LA BEST LOSS= 0.10999562900386498

VM BEST LOSS= 0.1114253723221217



图 3.1：四腔室原图、标签和识别结果，以及左心室长轴结果图（来自 Patient0001）

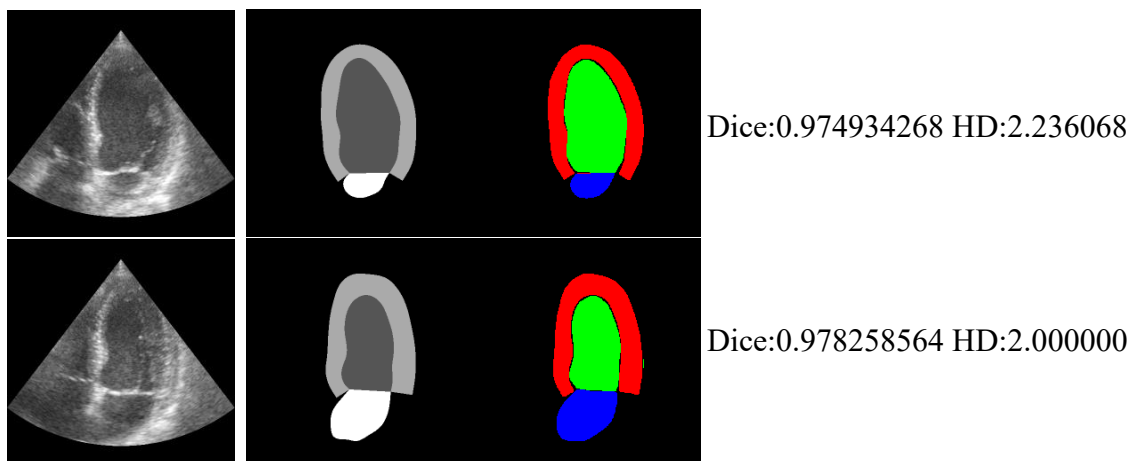


图 3.2：对应 Dice 系数和 Hausdorff 距离计算结果图（来自 Patient0500）

对于 100 例患者的 ES 帧和 ED 帧（共 200 张图片）的预测分割和标签：

平均 Dice 系数 = 0.9821741907118485，

指定尺寸（ 256×256 ）下 Hausdorff 距离 = 21.064782。




图 3.3: A4C 下 Dice 系数和 Hausdorff 距离结果图（来自 Patient0401-500 的 200 张图片）

3.1.2 二腔室识别分割模型

二腔室和四腔室训练过程与效果相仿。

使用 256×256 的 png 图片进行训练。训练模型 U-Net3+, 迭代轮数 EPOCHS = 100, 批数量 BATCH_SIZE = 20, 前期模型学习率 LR=0.1, 在模型接近 BEST LOSS 后 LR=0.001。

每个 Epoch 包含 464 个 Batch（共 9268 张图片和 9268 个标签）。更改标签类型（左心房 LA, 左心室 LV, 心室壁 VM）分别训练。

图像加强的缩放因子 SCALE = 5, 像素区分阈值 THRESHOLD = 0.5。

训练完成形成 path 文件并输出 BEST LOSS（最佳损失函数）。在二腔室的训练过程中，添加了对 Dice 系数随 Epoch 变化的输出。

训练结果：

LV BEST LOSS = 0.09246061700556812, DICE = 0.9794664623151565

LA BEST LOSS = 0.10468672521026998, DICE = 0.9745108202613634

VM BEST LOSS = 0.13544731317409153, DICE = 0.9615286363866823




图 3.4: 二腔室原图、灰度标签和识别结果, 以及左心室长轴结果图 (来自 Patient0001)

对于 100 例患者的 ES 帧和 ED 帧 (共 200 张图片) 的预测分割和标签:

平均 Dice 系数 = 0.986308459,

指定尺寸 (256×256) 下 Hausdorff 距离 = 22.22173114。

经过图像增强优化的 U-Net3+ 算法的分割结果与手动标注结果基本一致, 在心脏轮廓及其周围组织的分割边界方面表现较好, 具有很好的分割精度。对于图像质量标记为“差”的图片的鲁棒性依旧良好。




图 3.5: A2C 下 Dice 系数和 Hausdorff 距离结果图 (来自 Patient0401-500 的 200 张图片)

3.2 射血分数的计算

目前国际公认 EF 计算指南方法为改良 Simpson 法, 即双平面圆盘法。需要四腔室和两腔室两个视角下的影像分别计算后获得数据, 然而在现实生活以及部分数据集里仅存在四腔视野下的影像, 因此我们尝试提出了四项式的影像补全方法。

四腔式影像补全方法主要有两种技术路线, 一种是基于传统的单平面 Simpson 法, 即将左心室的形状视为一颗稍有歪斜的子弹头, 利用祖暅原理对心室的截面

和心室的高度分层积分，实现对心室体积的预测。即：通过四腔视野下的心室各层宽度表示该层的截面积。

此外，还有椭球体积法。即将心室视为一个从中间某处截断的椭圆形球体，以二尖瓣环中点近似为该椭圆形球体的球心，则四腔视野的心室截面为长轴和短轴组成的椭球截面。以左心室四腔室下的截面积和心室长轴共同计算左心室近似体积，最终计算射血分数。

在射血分数的计算过程中，我们将使用判定系数 R^2 和平均绝对误差（Mean Absolute Error, MAE）对预测结果进行评价。

在实现 EF 的计算前，必须逐帧获得每帧图像的二尖瓣环中点以及长轴，并且一些技术路线中还需要将长轴作为参考系进行分层切分。通过对输入视频切逐帧进行识别和体积计算，识别出每心动周期中最大左心室体积和最小心室体积，分别标记为 ED 帧和 ES 帧，以此计算 EF。

为此，我们开发了基于 O'Rourke 原理的长轴标记算法。该计算方法通过识别分割获得的心室掩膜（下图绿色）边缘，勾画该边缘的最小外接锐角三角形。首先使用 OpenCV 库函数识别区域的轮廓，遍历轮廓上的每一点，分别确定区域轮廓上距离三角形顶点最近的三个点，其中 x 值最小的点为心尖，剩余的两个点为二尖瓣环。随后，确定连接心尖和二尖瓣环中点的线段，该线段所在的直线记为中线，找到中线与左心室区域轮廓的交点。

由于轮廓为不规则形状，遍历轮廓上每一个点，逐一寻找该点和相邻点形成的线段与中线的交点。此时会找到两个交点，其中一个交点在心尖附近，将其舍去，另外一点即为左心室基底点。心尖到左心室基底点的距离为左心室长轴长度 L 。

通过此方法，可以实现对左心室结构外接最小三角形的自动勾画，通过确定方向的外接最小三角形获取二尖瓣环中点和心尖位置，进而可以间接获取左心室的截面积和体积。




图 3.6: ED 帧和 ES 帧的心室面积与长轴标记结果图

$L_{ED} = 127.012, A_{ED} = 7216. L_{ES} = 105.043. A_{ES} = 5052. Patient0500$

此外，当需要识别心室截面面积时，直接使用像素计量方法对生成的掩膜中的绿色像素点进行计数，以像素点的数量作为左心室截面的相对面积。

3.2.1 基于四腔室影像补全的射血分数计算与评价

首先，我们研究了基于左心室面积和长轴的左心室体积表示方法，对传统的单平面 Simpson 法进行复现。在该方法下沿心室长轴将心室平行切分为 20 层，利用每层与掩膜边缘交点间线段代表本层横向截面的圆盘直径。将心室视为 20 个圆盘堆叠积分而成。因此我们将长轴等分为 21 段等长线段，经其中 20 个端点作长轴的垂线，自下往上第 i 条垂线段长记为 a_i 。心室体积表示为下公式 (3.1)。其中 k 为消除“心室短切”体积误差的体积修正因子，一般取小于 1 的数。

$$V = k \sum_{i=1}^{20} \left(\frac{a_i^2 \pi}{4} \cdot \frac{L}{20} \right) \quad (3.1)$$




图 3.7: ED 帧和 ES 帧的长轴标记, 以及与长轴垂直的短轴结果图 (来自 Patient0500)

测试中发现, Patient401 和 Patient433 的心室 ED 面积小于 ES 面积, 心搏出功能严重衰竭, 不适合使用本公式。将这两个离群值排除后, 剩下的 98 例患者的 EF 预测值和数据集给定数值吻合良好。




图 3.8: 单平面 Simpson 法的 EF 值结果图

该模拟法射血分数 $MAE = 7.722260683$, $R^2 = 0.89753794$ 。可以见得单平面 Simpson 法预测的数值和真实值的相关性较为良好。但此方法下, 心室相对面积的计算误差较大, 导致 EF 的 MAE 较大, 实际应用效果有待考虑。

基于此, 通过对已有文献的学习和归纳, 我们得出了以下公式 (3.2), 将该方法记为“A4C L-A 单平面模拟法”。该公式中 A 为绿色像素面积, L 为心室长轴长度。的 V 以 voxel 为单位, 作为一个将心室量化的指标, 不等于实际体积。

$$V_i = \frac{128A_i^{\frac{5}{3}}}{3\pi L_i^{0.97}} \quad (3.2)$$

该方法仅仅使用心室面积和心室长度, 没有考虑到心室的长轴的倾角, 因此不能避免可能存在的“心室短切”问题。将 Patient401 和 Patient433 排除后, 剩下的 98 例患者的 EF 预测值和数据集给定数值吻合良好。




图 3.9: 单平面模拟法的 EF 值结果图

该模拟法射血分数 $MAE = 4.273083555$, $R^2 = 0.852773902$ 。可以发现我们提出的不经精确体积计算, 仅通过 L 和 A 进行相对面积表示的 EF 计算方法所获得的 MAE 小于单平面 Simpson 法。该方法的数据离散程度相较于前者稍大, 但仍处于可接受范围内。综合计算结果优于前者。

3.2.2 基于四腔室和二腔室影像的射血分数计算与评价

在单平面 Simpson 法的基础上, 我们研究了结合四腔室和二腔室视野的改良 Simpson 法。即, 将四腔室的 20 等分同样应用于二腔室视野, 将该 20 等分对应的分数分别表示为椭圆的长半径和短半径。四腔法的垂线段长度为 a_i 。二腔室的垂线

段长度即为 b_i ，则心室体积可以算得 (3.3)。此时不再需要 k 因子。

$$V = \sum_{i=1}^{20} \left(\frac{a_i b_i^2 \pi}{4} \cdot L_{ED} \cdot \frac{1}{20} \right) \quad (3.3)$$




图 3.10: ED 帧和 ES 帧的四腔室（上）和二腔室（下）标记，及与长轴垂直的短轴结果图

（来自 Patient0500）

测试中发现，排除离群值后，剩下的 98 例患者的 EF 预测值和数据集给定数值吻合优良。该模拟法射血分数 $MAE = 3.144390152$ ， $R^2 = 0.942115522$ 。




图 3.11: 改良 Simpson 法的 EF 值结果图

以下为三种方法的对比。可见改良 Simpson 法实际效果均最佳。




图 3.12: 三种方法对比以及 MAE 变化图

3.3 逐帧处理和帧连接分析

3.3.1 上采样性能评价

在实现了基于 U-Net 的逐帧分割和半周期/单周期射血分数计算后, 为处理现实数据中的问题、实现更好的预测, 我们还需要在逐帧处理的基础上进行帧连接连接分析。该过程需要对动态的视频中的各帧进行学习, 获取心室搏动的“涨落”过程 and 变化。

现实生活中, 由于医师的操作、超声设备的型号、患者的配合程度等等各种因素综合作用, 心动超声的影像质量往往低于 CMR、CT 等影像诊断。而权威数据集 EchoNet-Dynamic 所提供的 AVI 格式视频, 每帧仅有 112×112 像素大小, 无法有效实现视频质量和视频内容的评判。因此, 我们特意针对低质量、扭曲、清晰度差的视频和图片开发了上采样算法, 并进行性能评价。

该算法通过 OpenCV 库读取图像, 随后引入了一种三阶插值方法, 相比简单的最近邻或双线性插值, 提供更平滑的边缘和更少的锯齿效果。这种插值方法可以更好地保留图像的细节和结构信息, 使放大后的图像看起来更自然。8 位灰度的色彩存储保证了图像在放大后不会出现颜色失真, 并且可以与大多数图像处理工具兼容。

我们使用了来自 CAMUS_public 的数据进行测试。首先通过 OpenCV 默认的下采样方法将图片由数据集中原始的 512×512 下采样至 256×256 并与原图进行比较。随后我们将原图和由小尺寸图片上采样得到的图片进行比较, 评估该上采样算法的性能。一共测试了来自数据集的 10 组随机图片。平均 $SSIM = 0.974475017$, $MSE = 11.44406738$, $RMSE = 0.013136743$, $PSNR = 37.743132$ 。

效果如图 3.13。




图 3.13: 上采样测试。中间为原图，右图为上采样结果图

(SSIM = 0.973962614; MSE = 11.05064011; RMSE = 0.013036276; PSNR = 37.69112565dB)

3.3.2 心动周期分割与射血分数平均化

ResNet18_3D 是基于残差连接的三维时空卷积模型,在原始二维的基础上引入时间维度,从而可以捕捉视频中的时空信息。残差块将输入端信息直接连接到输出,从而解决深层网络训练中的梯度消失问题。采用该模型可以依据射血分数的初步预测值和超声心动视频进行时间增强,更好地提取关键帧附近的信息。

该项目采用单个采样和全采样两种方式对心动超声视频进行帧连接分析,每种采样方式都按照一定的采样周期选取固定帧长的视频片段。单个采样的视频片段随机选取起始帧,全采样则选取视频中所有满足帧长要求的片段。由于 CAMUS_public 心动超声视频仅有半个心动周期,样本数量小,训练后的模型不具备较好的泛化能力,本部分基于 EchoNet-Dynamic 完成训练和测试。

单个采样的射血分数预测值考虑了视频全局的帧连接,起到基础的预测作用。射血分数的预测平均绝对误差为 4.2%,均方根误差为 5.6%,R2 为 0.79。但是由于采样帧长的限制和采样的随机性,不同样本选取下预测差异较大。

结合全采样视频的射血分数逐帧预测和分割模型判断的心脏收缩末期有效帧可以进行心动周期的逐搏识别。以心脏收缩末期有效帧为中心,选取固定帧长的视频片段。由于每个超声心动图包含多个心动周期,取所有预测值的平均值作为最终的预测值。射血分数的预测平均绝对误差为 4.0%,均方根误差为 5.3%,R2 为 0.81,预测标准差的均值为 1.46。




图 3.14: 片段采样数对预测效果的影响图

依据不同心动周期采样数下射血分数预测值的平均绝对误差来评估逐搏预测的效果。图 3.14 示的 5 个箱线图分别代表 1, 2, 3, 4, 5 个心动周期采样数, 对于每一种采样数都随机选取 100 次与临床值进行比较。箱线图内的线代表数据中位数, 箱体上下边界分别为第三四分位数和第一四分位数, 须线延长到 1.5 倍的四分位距。当心动周期采样数为 5 时, 平均绝对误差的中位数值下降到 4.05%。可以看出随着心动周期采样数的增加, 射血分数的估计误差显著降低, 采样的随机性对预测效果的影响减小。

3.4 心力衰竭预测与综合评价

心率衰竭的预测主要通过射血分数的相对数值和心动周期预测值标准差获得。当射血分数过小, 一般低于 40% 时, 即可确定为心力衰竭; 而当射血分数在 40% 甚至 50% 以上时, 心力衰竭的预测则更多地需要结合不同心动周期的预测标准差来实现。多周期评价 EF 只能一定程度上表示该患者的心脏搏出能力, 而心脏的实际功能还需要通过不同周期的相互关系进行反馈。该部分基于 EchoNet-Dynamic 数据集训练。

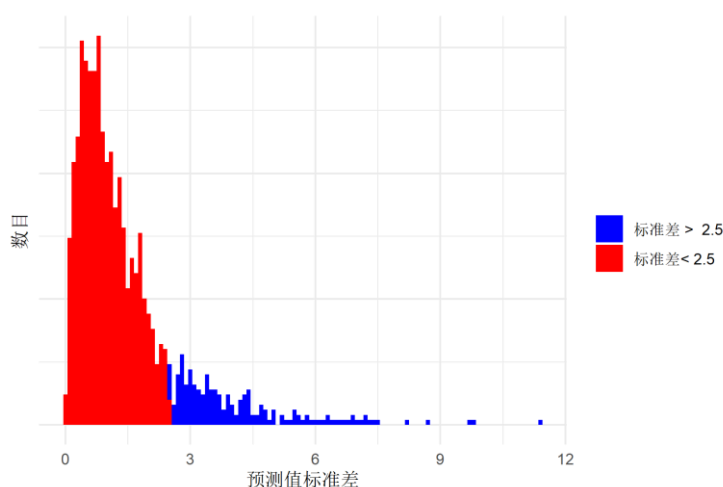


图 3.15: 片段采样数对预测效果的影响

当存在相当大的异位心律失常或变化时，建议对五个心动周期的测量结果取平均值，但由于工作的耗时，临床惯例上一般只取一个代表性心动周期并使用该代表性心动周期进行测量，而心动周期选择的主观性影响了预测准确性。采用逐搏分析的方法可以利用多个周期预测值的标准差来衡量患者的心功能，标准差 >2.5 表明不同心动周期间射血分数变化较大，可能存在异位心律失常等情况。

4 总结与展望

4.1 总结

本项目聚焦于开发一种基于超声心动图的心脏结构自动分割和射血分数计算方法。研究设计了一个包含结构分割臂和时空分析臂的综合方案，以实现从未标注的心动超声视频的自动处理和识别。

在计算射血分数方面，分别搭建并对比了三种不同的方法，同时考虑了四腔室和二腔室的影像，最终实现了对心脏结构的自动分割和容积识别，进而准确计算射血分数。四腔室分割 $\text{Dice} = 0.982174190$ ， $\text{Hausdorff Distance} = 21.064782$ ；二腔室分割 $\text{Dice} = 0.986308459$ ， $\text{Hausdorff Distance} = 22.22173114$ 。改良 Simpson 法 $\text{MAE} = 3.144390152$ ， $R^2 = 0.942115522$ 。

此外，还开发了上采样技术和时空卷积算法。总体而言，为了更准确地预测心力衰竭，研究还结合了射血分数和患者的人类学信息。通过实验和数据分析，研究验证了所提出方法的有效性和准确性。

4.2 在生成式人工智能与综合大模型时代的展望

随着生成式人工智能（Generative AI）和综合大模型（Comprehensive Large Models）技术的快速发展，医学图像分析领域正迎来新的变革。

新的分割模型例如 MedSAM（Medical Segmentation Attention Mechanism）正如雨后的春笋般涌现。这是一种针对医学图像分割的注意力机制的深度学习模型，通过引入注意力机制，能够更加精确地定位和分割医学图像中的感兴趣区域（如肿瘤、器官等）。能够实现多尺度特征融合、端到端的训练等，在多种医学图像分割任务中都展现出了优异的性能。通过不断的研究和改进，这类模型有望在未来取代传统 CNN 模型，更加接近“通用分割”的范畴。

生成式人工智能技术能够模拟和生成高质量的心脏图像，从而提高射血分数计算的准确性。通过深度学习算法，AI 能够生成逼真的心脏超声或 MRI 图像，弥补传统成像技术的不足。图像增强技术可以进一步改善图像质量，减少噪声和伪影，使心脏轮廓更加清晰，便于射血分数的精确计算。综合大模型技术能够整合多源数据，包括但不限于超声、MRI、CT 以及患者的遗传信息和生理数据等，为射血分数计算提供更全面、准确的信息。通过多模态数据融合，AI 模型能够捕捉到更多与心脏功能相关的特征，提高射血分数计算的敏感性和特异性。

在生成式人工智能和综合大模型的驱动下，射血分数的计算将实现自动化和

智能化。AI 模型能够自动勾划心内膜边界，计算心室容积，并据此得出射血分数。在早期诊断和病情监测方面，AI 模型能够实时分析患者的心脏图像数据，及时发现心脏功能异常，为早期干预提供科学依据。在治疗方案的制定方面，通过多模态数据融合和 AI 模型的智能分析，医生能够更准确地评估患者的心脏功能状态，为患者制定个性化的治疗方案。

随着生成式人工智能和综合大模型技术的不断发展，心功能的监视、分析与预测将更快速、准确和智能化。这将为心脏疾病的早期诊断、治疗及预后评估提供有力支持，推动心血管疾病诊疗水平的不断提升，切实造福全人类健康。

参考文献

- [1]Liu T ,Tian Y ,Zhao S , et al.Residual Convolutional Neural Network for Cardiac Image Segmentation and Heart Disease Diagnosis[J].IEEE Access,2020,882153-82161.
- [2]毕宇琪.基于人工神经网络的心脏图像分割和识别技术研究[D].长春工业大学,2023.
- [3]L. Toro-Quitian et al., Automatic estimation of the ejection fraction from diastole and systole ultrasound images by a simplified end-to-end U-Net neural network, 2023 19th International Symposium on Medical Information Processing and Analysis (SIPAIM), Mexico City, Mexico, 2023, pp. 1-5
- [4]Meghan Muldoon, Naimul Khan. Lightweight and Interpretable Left Ventricular Ejection Fraction Estimation Using Mobile U-Net. arXiv:2304.07951
- [5] Tokodi M, Magyar B, Soós A, Takeuchi M, Tolvaj M, Lakatos BK, Kitano T, Nabeshima Y, Fábíán A, Szigeti MB, Horváth A, Merkely B, Kovács A. Deep Learning-Based Prediction of Right Ventricular Ejection Fraction Using 2D Echocardiograms. JACC Cardiovasc Imaging. 2023 Aug;16(8):1005-1018.
- [6]Liu X, Fan Y, Li S, Chen M, Li M, Hau WK, Zhang H, Xu L, Lee AP. Deep learning-based automated left ventricular ejection fraction assessment using 2-D echocardiography. Am J Physiol Heart Circ Physiol. 2021 Aug 1;321(2):H390-H399.
- [7]Ouyang D, He B, Ghorbani A, Yuan N, Ebinger J, Langlotz CP, Heidenreich PA, Harrington RA, Liang DH, Ashley EA, Zou JY. Video-based AI for beat-to-beat assessment of cardiac function. Nature. 2020 Apr;580(7802):252-256.
- [8]国家心血管病中心, 国家心血管病专家委员会心力衰竭专业委员会, 中国医师协会心力衰竭专业委员会, 等. 国家心力衰竭指南 2023 [J]. 中华心力衰竭和心肌病杂志, 2023, 07(4): 215-311.
- [9]Ma J, He Y, Li F, Han L, You C, Wang B. Segment anything in medical images. Nat Commun. 2024 Jan 22;15(1):654.
- [10]H. Huang et al., UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation. ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Barcelona, Spain, 2020, pp. 1055-1059